

Türkçe Şarkı Sözlerinden Müzik Türü Sınıflandırması

Music Genre Classification from Turkish Lyrics

Önder Çoban, Gülşah Tümöklü Özyer
Bilgisayar Mühendisliği Bölümü
Atatürk Üniversitesi, Erzurum, Türkiye
Email: {onder.coban, gulsah.ozyer}@atauni.edu.tr

Özetçe —Internet ve kayıt teknolojilerinin gelişmesi ile dijital formda saklanabilen müzik sayısı sürekli artmaktadır. Bu artış ile birlikte müziklerin otomatik olarak organize edilmesi, çözülmesi gereken bir problem olarak ortaya çıkmıştır. Bu nedenle müzik bilgi getirimi (MIR, Music Information Retrieval) son yıllarda yaygın olarak çalışılan alanlardan birisidir. Geliştirilen müzik bilgi getirimi sistemleri ile otomatik çalma listesi oluşturma, hit şarkıları tespit etme, müzik türü veya ruh hali sınıflandırması gibi problemlere çözüm aranmaktadır. Yapılan çalışmalarda müziğin meta-data bilgisi, melodisi veya sözleri öznitelik elde etme amacıyla kullanılmaktadır. Türkçe için ise bu alanda yapılan çalışmaların yeterli sayıda olmadığı görülmektedir. Bu çalışmada, Türkçe şarkı sözlerinden oluşturulan veri seti otomatik olarak müzik türünün belirlenmesi amacıyla kullanılmıştır. Deneyisel sonuçlar Destek Vektör Makineleri (SVM, Support Vector Machines) algoritmasıyla elde edilmiş, metin sınıflandırma problemi olarak ele alınan müzik türü sınıflandırmasında öznitelik modellerinin etkisi incelenmiştir. Öznitelikler yapısal ve istatistiksel (SSTF, Structural and Statistical Text Features), kelime torbası (BoW, Bag of Words) ve NGram model ile elde edilmiştir. Sonuçlar müzik türü sınıflandırmasında şarkı sözlerinin Türkçe için etkili olabileceğini göstermiştir.

Anahtar Kelimeler—müzik bilgi getirimi, müzik türü sınıflandırması, şarkı sözü analizi, metin öznitelikleri, terim ağırlıklandırma.

Abstract—The amount of music in digital form increases due to the improvement of internet and recording technologies. With this increase, the automatic organization of musics has emerged as a problem needs to be solved. For this reason, Music Information Retrieval (MIR) is commonly studied research area in recent years. In this context, with the developed Music Information Systems solution is sought for some problems such as automatic playlist creation, hit song detection, music genre or mood classification etc. In previous works, meta-data information, melodic or textual content (lyrics) of music used for feature extraction. Also, it is seen that song lyrics not commonly used and number of work in this area is not enough for Turkish. In this paper, Turkish lyrics data set created and used for automatic music genre classification. Experimental results have been conducted on support vector machines (SVM) and the effect of feature model on results has been investigated in music genre classification which considered as a classical text classification problem. The features are extracted from three different models which are Structural and Statistical Text Features (SSTF), Bag of Words (BoW) and NGram. The results shows that lyrics can be effective for Turkish music genre classification.

Keywords—music information retrieval, music genre classification, lyric analysis, text features, term weighting.

I. GİRİŞ

Dijital ve çevrimiçi müzik sayısının artmasıyla birlikte müziklerin organize edilme gerekliliği ve kullanıcıların tür, stil, yıl vb. gibi özellikleri kullanarak istedikleri müziklere daha kolay ve hızlı bir şekilde erişme isteği ortaya çıkmıştır. Müzik bilgi getiriminde önemli bir yere sahip olan otomatik müzik sınıflandırma çalışmalarında sanatçı, kullanıcı etiketleri, müzik türü veya ruh hali sınıflandırması dikkat çeken araştırma alanlarıdır [1]. Bu çalışmalarda geliştirilen sistemler genellikle melodik içeriğe dayanmaktadır. Ancak son zamanlarda şarkı sözlerinin de tek başına veya melodik içerikle birlikte kullanılabilirliği görüşü önem kazanmıştır. Bu nedenle otomatik müzik türü sınıflandırması alanında şarkı sözleri melodik içerikle birlikte veya tek başına kullanılarak sistem performansının artırılması amaçlanmıştır [2], [3]. Bu çalışmada, müzik türü sınıflandırması Türkçe şarkı sözleri üzerinde uygulanmıştır. Bu amaçla literatürde bu alanda kullanılan SSTF (Structural and Statistical Text Features) modelin yanı sıra öznitelik modelinin etkisini incelemek amacıyla BoW (Bag of Words) ve NGram model de kullanılmıştır. Deneyisel sonuçlar farklı ağırlıklandırma yöntemleriyle elde edilmiştir. Ayrıca üç farklı modelde en iyi öznitelik ve ağırlıklandırma kombinasyonu birleştirilmiş, sonuçlar üzerinde etkisi incelenmiştir. Bildirinin geri kalan bölümleri şu şekilde düzenlenmiştir. Bölüm II’de ilgili çalışmalar incelenmiş, Bölüm III’de önileme, öznitelik modelleri, ağırlıklandırma ve sınıflandırma ile ilgili yöntemler açıklanmıştır. Oluşturulan veri setine ait bilgiler Bölüm IV’de verilmiştir. Bölüm V’de deneyisel sonuçlar verilmiş en iyi öznitelik ve ağırlıklandırma yöntemi incelenmiştir. Son bölümde sonuçlar özetlenmiş ve öneriler belirtilmiştir.

II. İLGİLİ ÇALIŞMALAR

Müzik bilgi getirimi sistemlerinde, şarkı sözleri tek başına veya melodik içerikle birlikte öznitelik kaynağı olarak bilgi getirimi sürecinde kullanılmaktadır [3]. Literatürde ingilizce şarkılar üzerinde daha önce yapılmış birçok çalışma mevcuttur. Yang ve Lee şarkı sözlerini melodik içerikle birlikte kullanılmış ve şarkı sözlerinden müziğin ruh halini tespit etmişlerdir [4]. Mayer ve Rauber web ortamından topladıkları şarkı sözlerini anlamsal ve yapısal olarak incelemiş tematik olarak sınıflandırmışlardır [5]. Van Zaanen ve Kanters şarkı sözlerinden elde ettikleri istatistiksel öznitelikleri tf-idf yöntemiyle ağırlıklandırmış, müzik ruh hali tespiti için kullanmışlardır [6]. McKay vd. yapısal ve istatistiksel öznitelikleri kullanarak şarkı sözlerinin müzik türü sınıflandırmasına etkisini incelemiştir [1]. Mayer vd. yine müzik türü sınıflandırması için şarkı sözlerini kullanmış, kelime torbası ve istatistiksel modelin yanı sıra sözcük türü etiketleri ve uyak şablon özniteliklerinin sınıflandırma sonuçları üzerinde etkisini

Tablo I. SSTFI VE SSTFII GRUBU ÖZNİTELİKLERİ

Öznitelikler				
SSTFI	Cümle Başına Düşen Kelime Oranı	Durak Kelime Oranı	Ortalama Satır Uzunluğu	Segment Başına Düşen Satır Sayısı
	Çapraz Uyak Sayısı (ABAB BABA)	Toplam Satır Sayısı	Ortalama Kelime Uzunluğu	Düz Uyak Sayısı (AA BB)
	Segment Başına Düşen Ortalama Satır	Boş Satır Sayısı	Ortalama Cümle Uzunluğu	Sarmal Uyak Sayısı (ABBA BAAB)
	İkili Düz Uyak Sayısı (AABB BBAA)	Segment Sayısı	Cümle Sayısı	Benzersiz Uyak Kelimeleri Sayısı
SSTFII	Kelime Başına Düşen Hece Oranı	Kelime Sayısı	Satır Başına Düşen Kelime Oranı	(-) Tire İşareti Sayısı
	Kelime Başına Düşen Karakter Oranı	Sayısal Değer Sayısı	(") Çift Tırnak Sayısı	(...) Üç Nokta Sayısı
	Kelime Başına Düşen Karakter Varyansı	Kelime Zenginliği Oranı	(:) İki Nokta Sayısı	(!) Ünlem İşareti Sayısı
	Satır Başına Düşen Benzersiz Kelime Oranı	Benzersiz Kelime Sayısı	(;) Noktalı Virgül Sayısı	(.) Virgül Sayısı
	Satır Başına Düşen Kelime Varyansı	Noktalama İşaretleri Oranı	(?) Soru İşareti Sayısı	(*) Yıldız Sayısı

incelemiştir [13]. Türkçe için ise Kirmaci ve Ogul şarkı sözlerinden elde ettikleri 4 farklı öznitelik kümesi ile söz yazarı ve şarkı türünü yaklaşık %55 başarıyla otomatik olarak tespit etmişlerdir [7]. Bu çalışma dışında literatürde Türkçe şarkı sözleri üzerinde, müzik bilgi getirimi alanında makine öğrenmesi yaklaşımıyla müzik türü sınıflandırması problemi için yapılan bir çalışma tespit edilememiştir.

III. YÖNTEMLER

Müzik bilgi getirimi sistemlerinde müzik yaygın olarak ses veya sembolik düzeyde analiz edilmektedir. Şarkılar ses dalgaları veya kayıtlar kullanılarak hesaplanan düşük seviye öznitelikler ile temsil edilmektedir. Buna ek olarak enstrümantal şarkılar hariç bir şarkının sözleri metinsel içerik olarak ele alınabilir ve klasik metin işleme teknikleri ile işlenerek bilgi getirimi sağlanabilir [13]. Bu nedenle çalışmamızda müzik türü sınıflandırması, bir metin sınıflandırma problemi olarak ele alınmıştır.

A. Önişleme

Şarkı sözleri nakarat, dördlük veya segment bloklarından meydana gelen kendine özgü biçimsel özelliklere sahip metinsel içeriklerdir. Bunun yanı sıra şarkı sözleri genellikle uyak içerecek ve belirli bir şablona bağlı kalacak şekilde düzenlenir. Müzik türü sınıflandırmasında bu vb. gibi yapısal öznitelikleri şarkı sözlerinden elde etmek melodisine kıyasla daha kolaydır ancak şarkı sözlerinin özel önişleme tekniklerinden geçirilmesi gerekmektedir [3], [8]. Çalışmamızda öznitelikler üç farklı modelde elde edilmiş ve şarkı sözleri her modelde farklı önişlemlerden geçirilmiştir. Tüm modellerde ortak olarak metin içeriği üzerinde küçük harf dönüşümü uygulanmış ve öznitelik olarak kabul edilmeyen bilgiler ve tüm karakterler temizlenmiştir. Ayrıca segmentler arasında tek satır boşluğu olması sağlanmış ve nakaratlar tek segmente indirgenmemiştir. NGram ve BoW modelde ortak işlemlere ek olarak harfler dışında tüm noktalama işaretleri ve karakterler de metin içeriğinden çıkarılmış, terimler için uzunluk ve frekans filtresi uygulanmamıştır. Her üç modelde anlamsal işlemler için Türkçe bir doğal dil işleme kütüphanesi olan Zemberek¹ kullanılmıştır [20]. Metin içerisindeki durak kelime oranının bulunması aşamasında ise Lucene² API'de bulunan Türkçe durak kelimeler listesi kullanılmıştır.

B. Öznitelikler

Veri setindeki her bir şarkının temsiline, metin sınıflandırma çalışmalarında yaygın olarak kullanılan vektör

uzay modeli [14] kullanılmıştır. Öznitelikler ise SSTF, BoW ve NGram olmak üzere üç farklı model ile elde edilmiştir.

SSTF Model: Bu model, kendine özgü biçimsel ve istatistiksel özelliklere sahip olan metinlerin kullanıldığı yazar tanıma, metin türü tanıma, müzik türü sınıflandırması vb. gibi çalışmalarda yaygın olarak kullanılmaktadır [9], [10]. Bu çalışmada literatürde kullanılan öznitelikler dikkate alınarak şarkı sözlerinden yapısal ve istatistiksel öznitelikler elde edilmiştir. Bu öznitelikler SSTFI (yapısal), SSTFII (istatistiksel) ve SSTFIII (sözcük türü etiketleri) olmak üzere üç ayrı gruba ayrılmıştır [1], [13], [2]. SSTFI³ ve SSTFII gruplarının içerdiği öznitelikler Tablo I'de verilmiştir. Sözcük türü etiketleri (POS Tags, Part of Speech Tags) grubunda ise edat, fiil, isim, sıfat, zamir, bağlaç, fiil+sıfat, fiil+isim ve isim+sıfat frekansları öznitelik olarak kullanılmıştır. Yapısal öznitelikler grubuna [13]'de kullanılan yöntemle uyak şablon frekansları da dahil edilmiştir. Uyak şablonlarının öznitelik olarak kullanıldığı çalışmalarda literatürde sadece kelime sonlarındaki hece benzerliği yeterli olmamakta bunun yanı sıra ses benzerliği de aranmaktadır. Ancak Türkçe'de kelimeler yazıldığı gibi okunduğu için çalışmamızda hece benzerliği yeterli şart kabul edilmiştir. Uyak şablonları tespit edilirken yarım kafiye (tek ses benzerliği) dışındaki kafiyeler (iki veya daha fazla ses benzerliği) dikkate alınmıştır. Türkçe'de satır sonlarında bulunan aynı kelimelerde (redif) de ses benzerliği görülmektedir ancak çalışmamızda aralarında ses benzerliği bulunan kelimelerin redif veya uyak olup olmadığı kontrol edilmemiş bu nedenle redifler de uyak olarak kabul edilmiştir.

BoW Model: Veri setindeki örnek temsili, öğrenme sisteminin genelleme yeteneği üzerinde oldukça etkilidir. BoW modelde bu temsil genellikle kelime-frekans ilişkilendirilmesi yapılarak sınıflandırma işlemi için uygun hale dönüştürülmesi ile olmaktadır [19]. Metin içeriğinden çıkarılan her bir kelime öznitelik, kelimenin gözlenme frekansı ise özniteliğin değeri olmaktadır. Ayrıca bu modelde kelimelerin metin içerisindeki sırasının önemli olmadığı kabul edilmektedir [18].

NGram Model: Metin sınıflandırma çalışmalarında kullanılan alternatif bir öznitelik elde etme modelidir. Kelime ve karakter düzeyinde olmak üzere iki farklı şekilde uygulanabilmektedir. Ancak karakter seviye modelin genellikle kelime seviye modelden daha başarılı olduğu tespit edilmiştir [11]. Karakter seviye ngram modelde öznitelikler metin içeriğinden çıkarılan n karakter uzunluğundaki karakter katarından oluşmaktadır. Bu yönüyle dilden bağımsız olan karakter seviye ngram model, yazım yanlışları ve kısaltma kullanımı gibi durumlara karşı güçlü olmakta ve çeşitli seviyelerde bilgi çıkarılmasına imkân vermektedir [12]. Bu çalışmada ngram

¹<https://code.google.com/p/zemberek/>

²<http://lucene.apache.org/>

³Uyak şablon özniteliklerini (AA, AABB, ABAB, ABBA) içermektedir.

modelde öznitelikler karakter seviyesinde iki (bigram), üç (trigram) ve dört (four-gram) karakter uzunluğunda olmak üzere üç farklı şekilde elde edilmiştir.

C. Ağırlıklandırma

Ağırlıklandırma işlemi örnek vektöründeki her bir öznitelik için önem derecesini belirtmek amacıyla bir ağırlık belirlenmesidir. Bu çalışmada öznitelikler, aşağıdaki eşitliklerde verilen terim frekansı (TF, Term Frequency), terim frekansı-ters doküman frekansı (TF-IDF, Term Frequency-Inverse Document Frequency), genişletilmiş normalize terim frekansı (ANTF, Augmented Normalized Term Frequency) ve ölçeklenmiş terim frekansı (STF, Sublinear TF Scaling) olmak üzere dört farklı yöntem ile ağırlıklandırılmıştır [16], [17].

$$W_{TF}(f, s) = TF(f, s) \quad (1)$$

$$W_{TF-IDF}(f, s) = TF(f, s) * IDF(f) \quad (2)$$

$$W_{ANTF}(f, s) = 0.5 + \frac{0.5 * TF(f, s)}{\max(TF_{f,s} : f \in s)} \quad (3)$$

$$WF(f, s) = \begin{cases} 1 + \log TF(f, s), & TF(f, s) > 0 \\ 0, & \text{diğer durumlar} \end{cases} \quad (4)$$

$$W_{STF}(f, s) = WF(f, s) * IDF(f) \quad (5)$$

W ağırlıklandırma fonksiyonunu, s bir örneği (şarkı sözünü), f bir terimi (öznitelik) ve N toplam örnek sayısını temsil eder.

D. Sınıflandırma

Sınıflandırma işlemi daha önce görülmemiş ve kategorisi bilinmeyen bir örneğe, eğitim verisi kategorilerinden en uygun olan kategorinin atanmasıdır. Bu çalışmada sınıflandırıcı olarak müzik türü sınıflandırması çalışmalarında yaygın olarak kullanılan ve genellikle en başarılı yöntem olan Destek Vektör Makineleri algoritması kullanılmıştır [15].

IV. VERİ SETİ

Müzik türü sınıflandırması çalışmalarında kullanılabilecek Türkçe şarkı sözlerinden oluşan ve herkese açık bir veri seti mevcut değildir. Bu nedenle geliştirdiğimiz web örümceği ile otomatik olarak toplanan Türkçe şarkı sözlerini içeren bir veri seti oluşturulmuştur. Oluşturulan veri seti rock, rap, arabesk, pop ve halk müziği türlerinde olmak üzere ilgili türde popüler olmuş 5 farklı sanatçının seslendirdiği şarkı sözlerinden meydana gelmektedir. Bir sanatçının hangi müzik türüne dahil edileceğine karar verilirken sadece ilgili türde şarkılar seslendiriyor olması koşulu aranmıştır. Daha sonra her bir sanatçının seslendirdiği, rastgele seçilen 50 şarkı sözü alınarak toplamda 1250 Türkçe şarkı sözü içeren veri seti elde edilmiştir.

V. DENEYSEL SONUÇLAR

Türkçe şarkı sözlerinden oluşan veri seti yöntemlerde açıklanan önışlemden geçirildikten sonra üç farklı modelde öznitelik elde edilmiştir. Bunun yanı sıra ağırlıklandırma yöntemlerinin sınıflandırma başarısı üzerindeki etkisini incelemek amacıyla farklı ağırlıklandırma yöntemleri kullanılmıştır. SSTF

Tablo II. DENEYLERDE KULLANILAN ÖZNİTELİKLER VE KODLARI

Öznitelik Grubu / Modeli		Kodu
SSTF	Yapısal (Biçimsel) Öznitelikler	SSTFI
	İstatistiksel Öznitelikler	SSTFII
	Sözcük Türü Frekansları (POS Tags)	SSTFIII
	Uyak Şablonları (AA, AAB, ABAB, ABBA)	SSTFU
	SSTFI + SSTFII + SSTFIII	SSTF
BoW	BoW + Kök Bulma	BoWS
	BoW + Durak Kelime Çıkarma	BoWRS
	BoW + Kök Bulma + Durak Kelime Çıkarma	BoW
NGram	Bigram	NGB
	Trigram	NGT
	Four-gram	NGF
Birleşik	BoW + NGram	BWNG
	SSTF + BoW	SSBW
	NGram + SSTF	NGSS

modelin içerdiği toplam 42 öznitelik üç gruba ayrılmıştır. BoW modelde durak kelimelerin çıkarılması ve kök bulma işlemlerinin etkisini inceleyebilmek amacıyla öznitelikler üç farklı şekilde elde edilmiştir. NGram modelde öznitelikler bigram, trigram ve four-gram olmak üzere farklı seviyelerde elde edilmiştir. Ayrıca her modelde, en iyi öznitelik tipi ve ağırlıklandırma yöntemi alınarak kendi aralarında birleştirilmiş ve sonuçlara olan etkisi incelenmiştir. Birleştirilmiş modelde öznitelikler elde edilirken tekrar ağırlıklandırılmamış, en başarılı sonuçların elde edildiği ağırlıklar kullanılmıştır. Deneylerde kullanılan öznitelik tipleri ve kodları Tablo II'de verilmiştir.

Sınıflandırma aşamasında deneyler 10-kat çapraz geçirme yöntemi ile gerçekleştirilmiş ve destek vektör makineleri algoritması libsvm⁴ paketi ile uygulanmıştır. Öznitelik modeli ve ağırlıklandırma yöntemi kombinasyonları kullanılarak gerçekleştirilen deneylerde elde edilen sonuçlar ise Tablo III ve Tablo IV'de verilmiştir. Sınıflandırıcının performans değerlendirmesinde başarı ölçütü olarak doğruluk metriği kullanılmıştır. Deney sonuçlarına göre, SSTF modelinin içerdiği üç farklı alt öznitelik grubu arasında en başarılı grup SSTFI yani yapısal öznitelikleri içeren grup olmuştur. Ayrıca SSTFI grubunda bulunan uyak şablon özniteliklerinin (SSTFU) de tek başına sonuçlar üzerine etkisi incelenmiş ve yeterli başarıyı sağlayamadığı tespit edilmiştir. SSTF modelde en iyi başarı bu modeldeki tüm öznitelikler kullanıldığında elde edilmiş ve TF en başarılı ağırlıklandırma yöntemi olmuştur. BoW modelde kök bulma ve durak kelimelerin çıkarılması işlemleri birlikte uygulandığında, kullanılan ağırlıklandırma yöntemine bağlı olarak değişiklik göstermekle beraber sınıflandırma başarısını düşürmüştür. Bunun yanı sıra BoW modelde en yüksek başarı sadece kök bulma işlemi uygulandığında elde edilmiş ve bu modelde en başarılı ağırlıklandırma yöntemi ANTF olmuştur. NGram modelde karakter seviyesi arttıkça başarı oranı artmış, bigram için TF ve TF-IDF, trigram için STF ve four-gram için ANTF en başarılı ağırlıklandırma yöntemi olmuştur. Deney sonuçları incelendiğinde model bazlı sonuçlarda NGram en başarılı öznitelik modeli olmuştur. Ayrıca birleştirilmiş modelin de sonuçlar üzerinde etkisi incelenmiş ve birleştirilmiş öznitelik modeli ile yapılan deneylerde sınıflandırma başarısının arttığı tespit edilmiştir. Tüm deneylerde en yüksek %73,79 doğruluk oranıyla müzik türü sınıflandırması gerçek-

⁴<https://www.csie.ntu.edu.tw/~cjlin/libsvm/>

Tablo III. ÖZNETELİK GRUPLARI VE FARKLI AĞIRLIKLANDIRMA YÖNTEMLERİ İÇİN DOĞRU SINIFLANDIRMA BAŞARILARI (%)

Öznitelik	Ağırlıklandırma Yöntemi			
	ANTF	STF	TF	TF-IDF
SSTFU	29,64	35,87	35,05	35,05
SSTFI	46,02	48,56	59,62	48,72
SSTFII	51,43	37,59	52,90	34,97
SSTFIII	34,31	42,09	46,02	42,17
SSTF	55,36	54,13	62,89	50,53
BoWS	69,45	68,14	65,02	65,02
BoWRS	69,36	69,28	67,89	67,89
BoW	68,30	68,14	65,35	65,35
NGB	63,06	63,96	65,35	65,35
NGT	69,94	71,17	66,66	66,66
NGF	73,05	70,84	67,97	67,97

Tablo IV. BİRLEŞTİRİLMİŞ ÖZNETELİK GRUPLARI İÇİN DOĞRU SINIFLANDIRMA BAŞARILARI (%)

Öznitelik	Sınıflandırma Başarısı (%)
SSTF + BoW	69,45
BoW + NGram	73,79
NGram + SSTF	73,62

leştirilmiştir.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, otomatik müzik türü sınıflandırması Türkçe şarkı sözleri üzerinde uygulanmış ve kullanılan öznitelik modeli ile ağırlıklandırma yönteminin sınıflandırma başarısı üzerinde etkisi incelenmiştir. Müzik türü sınıflandırma, bir metin sınıflandırma problemi olarak ele alınmış ve klasik metin önileme ve sınıflandırma teknikleri kullanılmıştır. Elde edilen sonuçlar ile literatürde İngilizce şarkılar üzerinde yapılan çalışmalarda elde edilen başarı Türkçe için yakalanmıştır. Şarkı sözlerinin de köşe yazısı, şiir vb. metinlerde olduğu gibi kendine özgü yapısal özellikleri mevcuttur ve bu yönüyle hem biçimsel hem istatistiksel özelliklerin elde edilmesine elverişlidir. Ancak literatürdeki başarı yakalanmış olsa da SSTF model BoW ve NGram modellerden daha başarılı değildir. Ayrıca kullanılan özelliklerin çoğunlukta olan kısmının ayırt edici niteliğe sahip olmaması yüksek başarı elde edilmesini engellemiştir. Bu durumun en önemli nedeni şarkı sözlerinin belirli bir düzene bağlı kalınmadan saklanması ve dijital ortamlarda değişiklik gösterebilmesidir. BoW ve NGram model daha başarılı olmakla beraber elde edilen öznitelik sayısı çok daha fazla olduğundan performans bakımından dezavantajlı konumdadır. SSTF modelde ise elde edilen öznitelik sayısı diğer iki model ile kıyaslanamayacak kadar az olmak ve çok büyük bir performans avantajı sağlamaktadır. Sınıflandırma başarısında, kullanılan eğitim verisinin ve elde edilen özelliklerin doğrudan etkisi olmakta ve eğitim verisi boyutu arttıkça sınıflandırıcının genelleme yapma yeteneği genellikle artmaktadır. Bu sebeple başarıyı artırmak amacıyla eğitim verisi boyutunun arttığı düşünüldüğünde SSTF modelin performans bakımından daha avantajlı olacağı açıktır. Bununla beraber SSTF model şarkının metinsel veya melodik içeriğinden çıkarılabilecek diğer özellikler ile birlikte kullanılabilir ve sınıflandırma başarısına olumlu katkı sağlayabilir. Böylece bu çalışmada olduğu gibi öznitelik uzay boyutu çok fazla artırılmadan farklı özellikler ile birleştirilip sınıflandırma

başarısı artırılabilir. Bu nedenle SSTF modelden vazgeçmek yerine gelecek çalışmalarda bu modelde kullanılan öznitelik kümesine ayırt edici yeni özelliklerin eklenmesi ve başarı oranının artırılması düşünülmektedir. Ayrıca bu çalışmada uzak tespitinde kullanılan algoritmanın tüm Türkçe uyak şablonlarını tespit edebilecek şekilde geliştirilerek sonuçlar üzerindeki etkisinin incelenmesi düşünülmektedir.

KAYNAKÇA

- [1] McKay Cory, et al. "Evaluating the Genre Classification Performance of Lyrical Features Relative to Audio, Symbolic and Cultural Features." ISMIR. 2010.
- [2] Hu Xiao, and J. Stephen Downie. "Improving mood classification in music digital libraries by combining lyrics and audio." Proceedings of the 10th annual joint conference on Digital libraries. ACM, 2010.
- [3] Ying Teh Chao, Shyamala Doraisamy, and Lili Nurliyana Abdullah. "Genre and mood classification using lyric features." Information Retrieval & Knowledge Management (CAMP), 2012 International Conference on. IEEE, 2012.
- [4] Yang Dan, and Won-Sook Lee. "Music emotion identification from lyrics." Multimedia, 2009. ISM'09. 11th IEEE International Symposium on. IEEE, 2009.
- [5] Mayer Rudolf, and Andreas Rauber. "Multimodal Aspects of Music Retrieval: Audio, Song Lyrics-and Beyond?." Advances in Music Information Retrieval. Springer Berlin Heidelberg, 2010. 333-363.
- [6] Van Zaanen Menno, and Pieter Kanter. "Automatic Mood Classification Using TF* IDF Based on Lyrics." ISMIR. 2010.
- [7] Kirmaci Basar, and Hasan Ogul. "Author recognition from lyrics." Signal Processing and Communications Applications Conference (SIU), 2015 23th. IEEE, 2015.
- [8] Hu Xiao, J. Stephen Downie, and Andreas F. Ehmann. "Lyric text mining in music mood classification." American music 183.5,049 (2009): 2-209.
- [9] Stamatos Efstathios, Nikos Fakotakis, and George Kokkinakis. "Automatic text categorization in terms of genre and author." Computational linguistics 26.4 (2000): 471-495.
- [10] Mayer Rudolf, Robert Neumayer, and Andreas Rauber. "Combination of audio and lyrics features for genre classification in digital audio collections." Proceedings of the 16th ACM international conference on Multimedia. ACM, 2008.
- [11] Kanaris Ioannis, et al. "Words vs. Character N-Grams for Anti-Spam Filtering."
- [12] Lodhi Huma, et al. "Text classification using string kernels." The Journal of Machine Learning Research 2 (2002): 419-444.
- [13] Mayer Rudolf, Robert Neumayer, and Andreas Rauber. "Rhyme and Style Features for Musical Genre Classification by Song Lyrics." ISMIR. 2008.
- [14] Salton Gerard, Anita Wong, and Chung-Shu Yang. "A vector space model for automatic indexing." Communications of the ACM 18.11 (1975): 613-620.
- [15] Joachims Thorsten. Text categorization with support vector machines: Learning with many relevant features. Springer Berlin Heidelberg, 1998.
- [16] Salton Gerard, and Christopher Buckley. "Term-weighting approaches in automatic text retrieval." Information processing & management 24.5 (1988): 513-523.
- [17] Manning Christopher D., Prabhakar Raghavan, and Hinrich Schütze. Introduction to information retrieval. Vol. 1. Cambridge: Cambridge university press, 2008.
- [18] Lewis, David D. "An evaluation of phrasal and clustered representations on a text categorization task." Proceedings of the 15th annual international ACM SIGIR conference on Research and development in information retrieval. ACM, 1992.
- [19] Joachims, Thorsten. A Probabilistic Analysis of the Rocchio Algorithm with TFIDF for Text Categorization. No. Cmu-Cs-96-118. Carnegie-Mellon Univ Pittsburgh Pa Dept of Computer Science, 1996.
- [20] Akın, Ahmet Afsin, and Mehmet Dünder Akın. "Zemberek, an open source NLP framework for Turkic Languages." Structure 10 (2007): 1-5.